

# Przeszukiwanie w grach

Paweł Rychlikowski

Instytut Informatyki UWr

9 kwietnia 2024



# Przykładowa gra

- Gracz **A** wybiera jeden z trzech zbiorów:
  1.  $\{-50, 50\}$
  2.  $\{1, 3\}$
  3.  $\{-5, 15\}$
- Następnie gracz **B** wybiera liczbę z tego zbioru.

## Pytanie

Co powinien zrobić **A**, żeby uzyskać jak największą liczbę?

## Nasza gra

1.  $\{-50, 50\}$
2.  $\{1, 3\}$
3.  $\{-5, 15\}$

Racjonalny wybór dla **A** zależy od (modelu) gracza **B**

- Współpracujący: Oczywiście 1.
- Losowy (z  $p = \frac{1}{2}$ )) Wybór 3 (średnio 5)
- „Złośliwy”: wybór 2 (gwarantujemy wartość 1)

- Nieco inna rodzina zadań wyszukiwania, w których mamy dwóch (lub więcej) agentów.
- Interesy agentów są (przynajmniej częściowo) rozbieżne.
- Rozgrywka przebiega w turach, w których gracze na zmianę wybierają swoje ruchy.

## Definicja

**Gra** jest problemem przeszukiwania, zadany przez następujące składowe:

1. Zbiór stanów, a w nim  $S_0$ , czyli stan początkowy
2.  $\text{player}(s)$ , funkcja określająca gracza, który gra w danym stanie.
3.  $\text{actions}(s)$  – zbiór ruchów możliwych w stanie  $s$
4.  $\text{result}(s,a)$  – funkcja zwracająca stan powstały w wyniku zastosowania akcji  $a$  w stanie  $s$ .
5.  $\text{terminal}(s)$  – funkcja sprawdzająca, czy dany stan kończy grę.
6.  $\text{utility}(s, \text{player})$  – funkcja o wartościach rzeczywistych, opisująca wynik gry z punktu widzenia danego gracza.

## Definicja

W **grze o sumie zerowej** suma wartości stanów terminalnych dla wszystkich graczy jest stała (niekonieczne zera, ale...)


Konsekwencje:

- Zysk jednego gracza, jest stratą drugiego.
- Kooperacja nic nie daje.

## Uwaga

Zaczniemy od gier o sumie zerowej i gracza, wcześniej nazwanego **złośliwym** (lepiej go nazwać **racjonalnym**)


# Drzewo gry






# Kółko i krzyżyk. Drzewo gry

## Fragment drzewa dla prawdziwej gry



## Inna prosta gra (2)

- Mamy dwóch graczy Max i Min (jeden chce maksymalizacji, drugi minimalizacji).
- Wartość dla Max-a to liczba przeciwna wartości dla Min-a.
- Mamy dwa ruchy, zaczyna gracz maksymalizujący.



# Algorytm MiniMax

```
MAX = 1
MIN = 0

def decision(state):
    """decision for MAX"""
    return max(a for actions(state),
               key = lambda a : minmax(result(a,state), MIN))

def minmax(state, player):
    if terminal(state): return utility(state)

    values = [minmax(result(a,state), 1-player) for a in actions(state)]
    if player == MIN:
        return min(values)
    else:
        return max(values)
```

Spotyka się różne warianty nazewniczne (niestety również na naszych slajdach):

- Algorytm MiniMax
- Algorytm min-max
- Algorytm MinMax

# Algorytm MiniMax

- $O(d)$  – pamięć
- $O(b^{2d})$  czas, gdzie  $d$  jest liczbą ply's (pótruchów)
- Dla szachów  $b \approx 35$ ,  $d \approx 50$
- Dla go: 250, 150

# Algorytm MiniMax (wersja realistyczna)

- Algorytm MiniMax działa jedynie dla bardzo małych, sztucznych gier (ewentualnie dla końcówek prawdziwych gier).
- Żeby go uczynić realistycznym, musimy:
  - a) Przerwać poszukiwania na jakiejś głębokości.
  - b) Umieć szacować wartość nieterminalnych sytuacji na planszy.

# Algorytm MinMax z głębokością

```
def decision(state):  
    return max([a for actions(state),  
                key = lambda a : minmax(result(a,state), MIN ,0)]])  
  
def minmax(state, player, depth):  
    if terminal(state): return utility(state)  
    if cut_off_test(state, depth):  
        return heuristic_value(state)  
  
    values = [minmax(result(a,state), 1-player, depth+1) for a in actions(state)]  
    if player == 0:  
        return min(values)  
    else:  
        return max(values)
```

# Algorytm MinMax z głębokością

```
def decision(state):  
    return max([a for actions(state),  
                key = lambda a : minmax(result(a,state), MIN ,0)]])  
  
def minmax(state, player, depth):  
    if terminal(state): return utility(state)  
    if cut_off_test(state, depth):  
        return heuristic_value(state)  
  
    values = [minmax(result(a,state), 1-player, depth+1) for a in actions(state)]  
    if player == 0:  
        return min(values)  
    else:  
        return max(values)
```



# Dwa parametry algorytmu wyszukiwania

1. **cut\_off\_test**: kiedy kończymy przeszukiwanie
  - najłatwiej: jak osiągniemy maksymalny poziom, biorąc pod uwagę możliwości
  - Nie jest to jedyne wyjście (ani najlepsze)
2. Co to znaczy funkcja **heuristic\_value**

# Jak szacować wartość sytuacji?

## Wariant 1

Korzystamy z wiedzy eksperta, próbując ją sformalizować.

## Wariant 2

Próbujemy zaprząć jakiś mechanizm uczenia (lub przeszukiwania), żeby tę funkcję wybrać.

# Jak szacować wartość sytuacji? (2)

Generalne wskazówki:

1. Przewaga materialna (więcej, lepszych figur)
2. Ustawienie figur (ruchliwość – liczba możliwych ruchów)
3. Szacowana liczba ruchów do zwycięstwa (zagrożony król, itp).
4. Ochrona naszych figur (jak mnie zbijesz, to ja cię zaraz zbiję)

# Aktywny goniec

Biały goniec wprowadzony do gry, czarny nie może nic zrobić.



# Przewaga materialna


- Wartość materialną liczą powszechnie szachiści:
  - a) pion: 1
  - b) skoczek, goniec: 3
  - c) wieża: 5
  - d) hetman: 9
- Sprawdzono doświadczalnie, że te wartości są dobrze dobrane (jak sobie wyobrazić taki eksperyment?)

## Uwaga

Nawet nie wiedząc nic o uczeniu, możemy sobie wyobrazić łatwo jakąś procedurę wyznaczania tych wartości. Na przykład:

1. Losujemy 100 zestawów:  
(1, wartość-gońca, wartość-skoczka, wartość-wieży, wartość-hetmana).
2. Przeprowadzamy pojedynki każdy z każdym.
3. Wybieramy zwycięzcę.

# Connect 4. Przykładowa gra



## Connect 4. Przykładowa gra



- Prosty, a zarazem grywalny wariant kółka i krzyżyka
- Dodatkowe elementy: mamy ciężenie i piony spadają, gramy do 4 w wierszu, kolumnie lub na przekątnej


## Connect 4. Zwycięska konfiguracja



- Prosty, a zarazem grywalny wariant kółka i krzyżyka
- Dodatkowe elementy: mamy ciężenie i piony spadają, gramy do 4 w wierszu, kolumnie lub na przekątnej



# Co to znaczy wzorzec w Connect 4?



- Analizujemy wszystkie czwórki pól (w każdej bowiem może się zdarzyć układ wygrywający)
- Czwórki, w których są pionki obu kolorów pomijamy
- Wyznaczamy wagę 1-ek, dwójek, trójek (być może zależnie od kierunków)

- Możliwe są większe wzorce, uwzględniające szerszy kontekst
- możliwe jest również **uczenie** większych wzorców. Na przykład za pomocą **splotowych sieci neuronowych (CNN)**.

## Uwaga

Takie sieci działały w AlphaGo.

- Funkcja oceny może być ważoną sumą zaobserwowanych wzorców.
- Wzór:

$$\sum_i w_i p_i$$

( $w_i$  – waga i-tego wzorca,  $p_i$  – ile razy ten wzorzec występuje na planszy)

- Niektóre wagi są dodatnie (mój dobry wzorzec, słabe ustawienie oponenta), inne ujemne.

# Drobna uwaga o ewolucji w grach: jak wyznaczyć parametry funkcji oceniającej?

- Istnieje pokusa, żeby zastosować algorytmy ewolucyjne (bo zadanie przypomina ewolucję, w której osobniki toczą ze sobą walkę).
- **Problem:** Jak wyznaczyć funkcję celu?
  - a) Rozgrywać turnieje, przystosowaniem jest średni wynik.
  - b) Wybrać grupę przeciwników (stałą), przystosowaniem X-a będzie średni wynik z tymi przeciwnikami.


## Uwaga

Opcja pełnej ewolucji trochę niebezpieczna, często łączy się oba warianty.


Drugi **metaparametr** funkcji obliczającej wartość planszy.

- Są dwa problemy związane z przerywaniem przeszukiwania:
  1. Przerwanie w niestabilnej sytuacji (na przykład w środku wymiany hetmanów)
  2. Tzw. efekt horyzontu (czyli widzimy, że coś się zdarzy, ale w odległej perspektywie)


# Efekt horyzontu (zła sytuacja czarnego gońca)



# Efekt horyzontu (zła sytuacja czarnego gońca)



## Efekt horyzontu (zła sytuacja czarnego gońca)





# Kończenie przeszukiwań w praktyce

- Nieprzerywanie, jeżeli przeciwnik ma bicie.
- Ogólniej: powyżej jakiejś głębokości rozważamy tylko ruchy **mocno zmieniające sytuację**

## Definicja

W **przeszukiwaniu z bezruchem** ( **quiescence search** ) możemy skończyć poszukiwanie **tylko** gdy sytuacja jest statyczna.

# Kończenie przeszukiwań w praktyce

- Można też stosować jakąś wersję *local beam search* (od któregoś momentu ograniczając mocno rozgałęzienie drzewa)
- Rozważa się warunek **singular extension**, czyli istnienie jednego ruchu, który jest wyraźnie (na oko) lepszy od innych. Takie ruchy zawsze wykonujemy, zwiększając głębokość, a nie zwiększając rozgałęzienia.

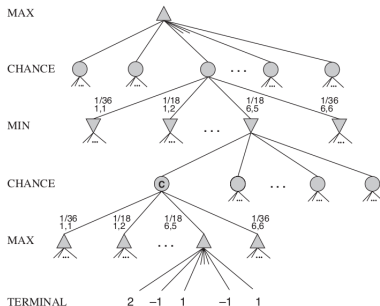
## Uwaga

Trochę tak działają ludzie.

- W niektórych grach (i w życiu) mamy element losowy.
- Prosty przykład: [szachy z kostką](#):
  - Przed ruchem wykonujemy rzut kostką, który determinuje czym możemy się ruszyć,
  - 1 - pionek, 2 - skoczek, 3 - goniec, 4 – wieża, 5 – hetman, 6 – król
  - Gramy do zbitcia króla.

# Losowość w grach

- Wprowadzamy dodatkowe węzły, czyli **chance nodes**.
- Przykładowe drzewo gry (dla losowania przy użyciu **dwóch kości**):



- Minimax, do którego dołożono węzły losowe.
- W węzłach losowych mamy wybór wartości oczekiwanej (sumowanie)

```
def emm(state, player):  
    if terminal(state): return utility(state)  
    if player == MIN:  
        return min( emm(result(state, a), next(player)) for a in actions(state))  
    if player == MAX:  
        return max( emm(result(state, a), next(player)) for a in actions(state))  
    if player == CHANCE:  
        return sum( P(r) * emm(result(state, r), next(player)) for r in actions(state))
```


# Wartość sytuacji w grach z losowością

## Uwaga 1

Dowolne monotoniczne przekształcenie nie zmienia ruchów wybieranych przez minimax!

## Uwaga 2

W grach z losowością powyższe zdanie przestaje być prawdziwe.



- Analiza gier z losowością jest nieco trudniejsza.
- Możemy skorzystać z następującej idei:  
*Oceniamy sytuację przeprowadzając dużo losowych gier rozpoczynających się w danej sytuacji*
- **Uwaga:** dwa rodzaje losowości: jeden związany z węzłami losowymi (dany przez grę), drugi związany z węzłami min/max – zamiast wyliczać ruch wykonujemy ruch losowy.

## Uwaga

Monte Carlo Simulation dotyczy nie tylko gier z losowością!

# Monte Carlo Simulation

- Zauważmy, że Monte Carlo Simulation jakoś rozwiązuje problem horyzontu (bo symulacje mogą być b. długie)
- Możemy losować ruchy z niejednakowym prawdopodobieństwem (preferując te, które lokalnie wyglądają sensownie)

## Uwaga

Bardzo ważnym nie tylko w grach jest algorytm **Monte Carlo Tree Search**, o którym jeszcze powiemy.